

Inteligência Computacional

Redes Neurais Artificiais

Introdução

Flávio Henrique Duarte de Araújo
flavio86@ufpi.edu.br

Motivação

Cérebro Humano

∴ Cérebro Humano

- o cérebro é um “computador” **complexo, não linear e paralelo;**

Ex: Sistema de Visão Humana (reconhecimento de formas , ambientes,etc.)

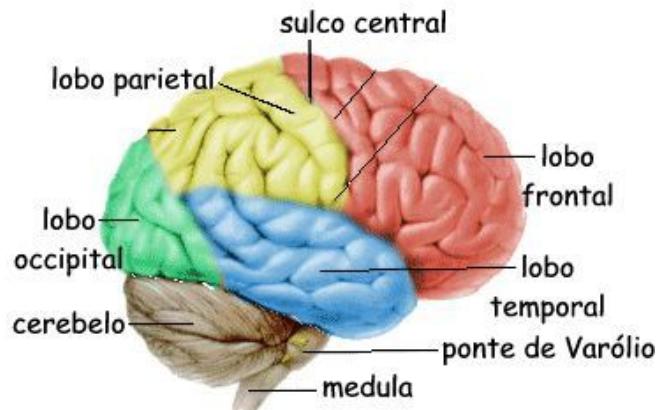
Sensoriamento de Animais (morcegos, golfinhos, falcões, etc.)

- possui a habilidade de **desenvolver regras através da experiência** (exemplos);

Ex: Quente/Frio, Doce/Amargo, Velho/Novo, etc.

- possui a capacidade de **trabalhar bem sem regras explícitas;**

Ex: Perceber/Agir



Motivação

Cérebro Humano

∴ Funcionamento

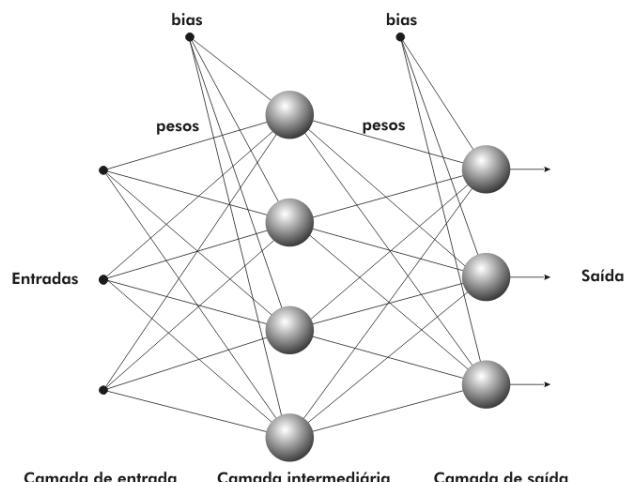
- o processamento de informação no cérebro é realizado por uma rede de bilhões de unidades de processamento simples chamados **neurônios**;
- essencialmente, cada neurônio recebe sinais de um grande número de outros neurônios, **combina essas entradas**, e então envia sinais a um grande número de outros neurônios.
- o **padrão de conexões** entre os neurônios que parece incorporar o conhecimento requerido para realizar o processamento de informações. Por isso, um nome alternativo para o processamento que imita o cérebro seria *computação conexionista*.

Redes Neurais

Definição

∴ O que é uma Rede Neural

“São sistemas paralelos distribuídos compostos por uma unidade de processamento simples (nodos) que calculam determinadas funções matemáticas (normalmente não lineares). Tais unidades são dispostas em uma ou mais camadas e são interligadas por um grande número de conexões, geralmente chamadas de unidades racionais. Na maioria dos modelos estas conexões estão associadas a pesos, os quais armazenam o conhecimento representado no modelo e servem para ponderar a entrada recebida por um neurônio da rede.” [HAYKIN 2004]

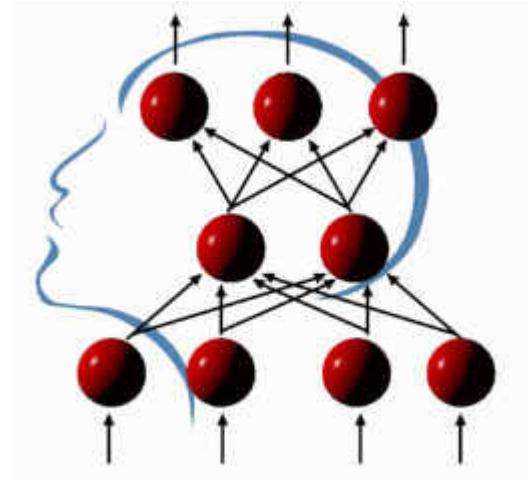


Redes Neurais

Benefícios

∴ **Benefícios**

- **Não-Lineres** (maioria dos sinais são não-lineres)
- **Mapeamento Entrada Saída** (não conhecimento do modelo)
- **Generalização** (Capacidade de operar com conhecimento parcial)
- **Adaptabilidade** (retreinamento)
- **Evidência** (medida de confiança)

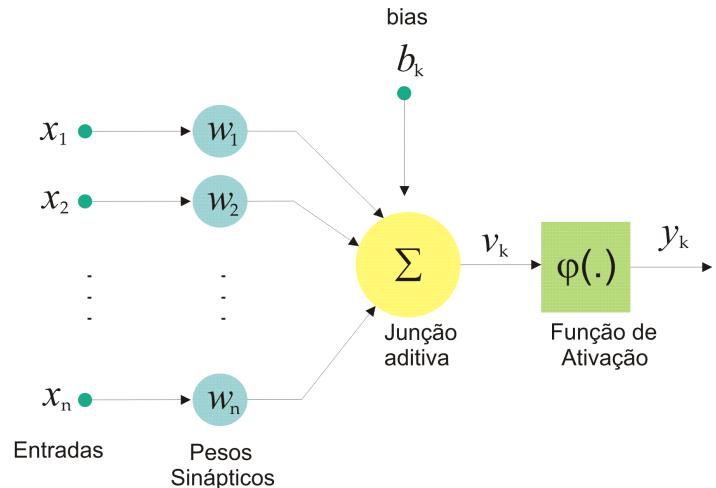


Neurônio de McCulloch-Pitts

Neurônio Artificial

∴ Modelo do Neurônio

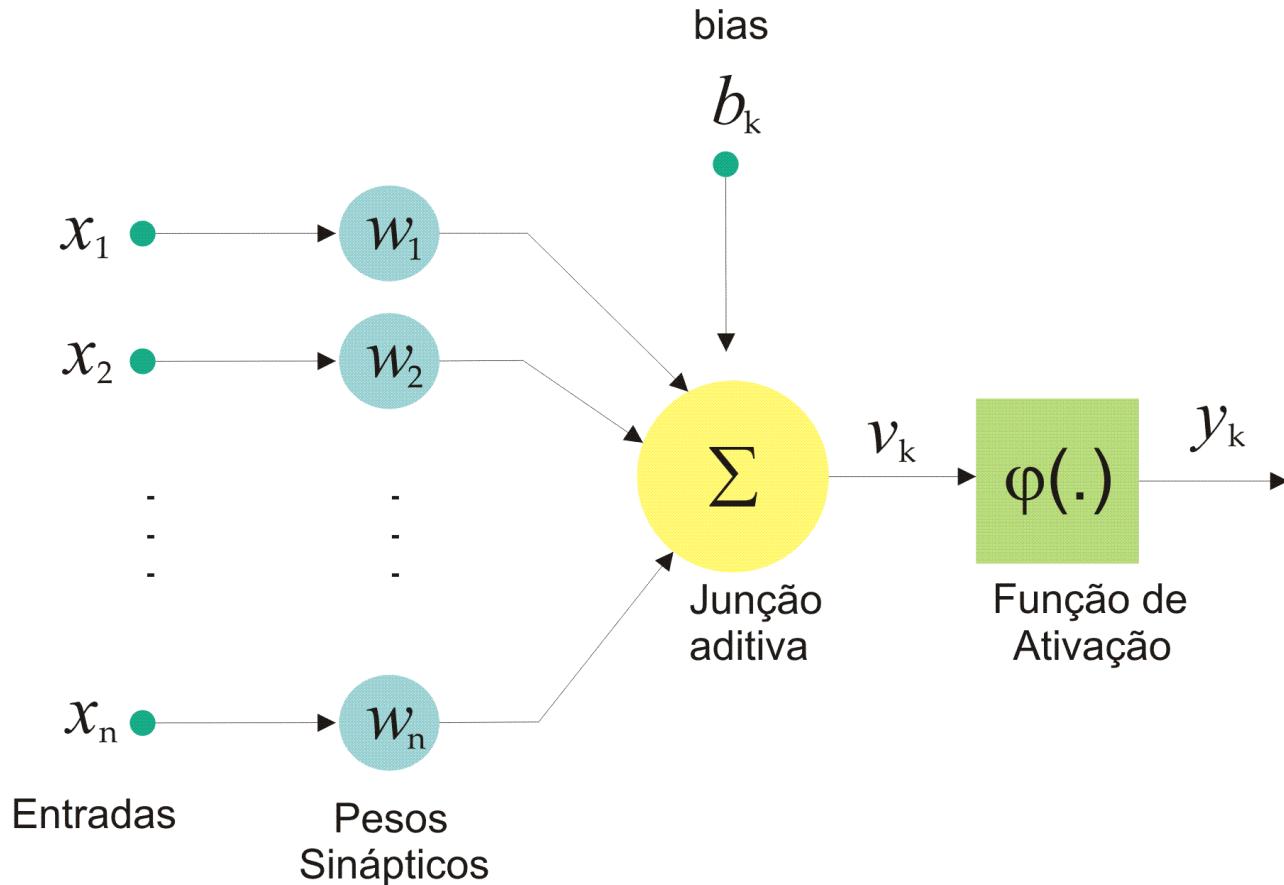
- Um conjunto de sinapses, ou elos de conexão, cada uma caracterizada por um **peso**. Um sinal x_j na **entrada** da sinapse j conectada ao neurônio k é multiplicada pelo peso w_k .
- Um **somador** para somar os sinais de entrada, ponderados pelas sinapses do neurônio.
- Uma **função de ativação** para restringir a amplitude da saída de um neurônio.
- O modelo neuronal também inclui um **bias** (b_k) que tem o efeito de aumentar ou diminuir a entrada líquida da função de ativação



Neurônio de McCulloch-Pitts

Neurônio Artificial

∴ **Modelo do Neurônio**



Neurônio de McCulloch-Pitts

Neurônio Artificial

∴ **Modelo Matemático do Neurônio**

Em termos matemáticos, podemos descrever um neurônio k pelo seguinte par de equações:

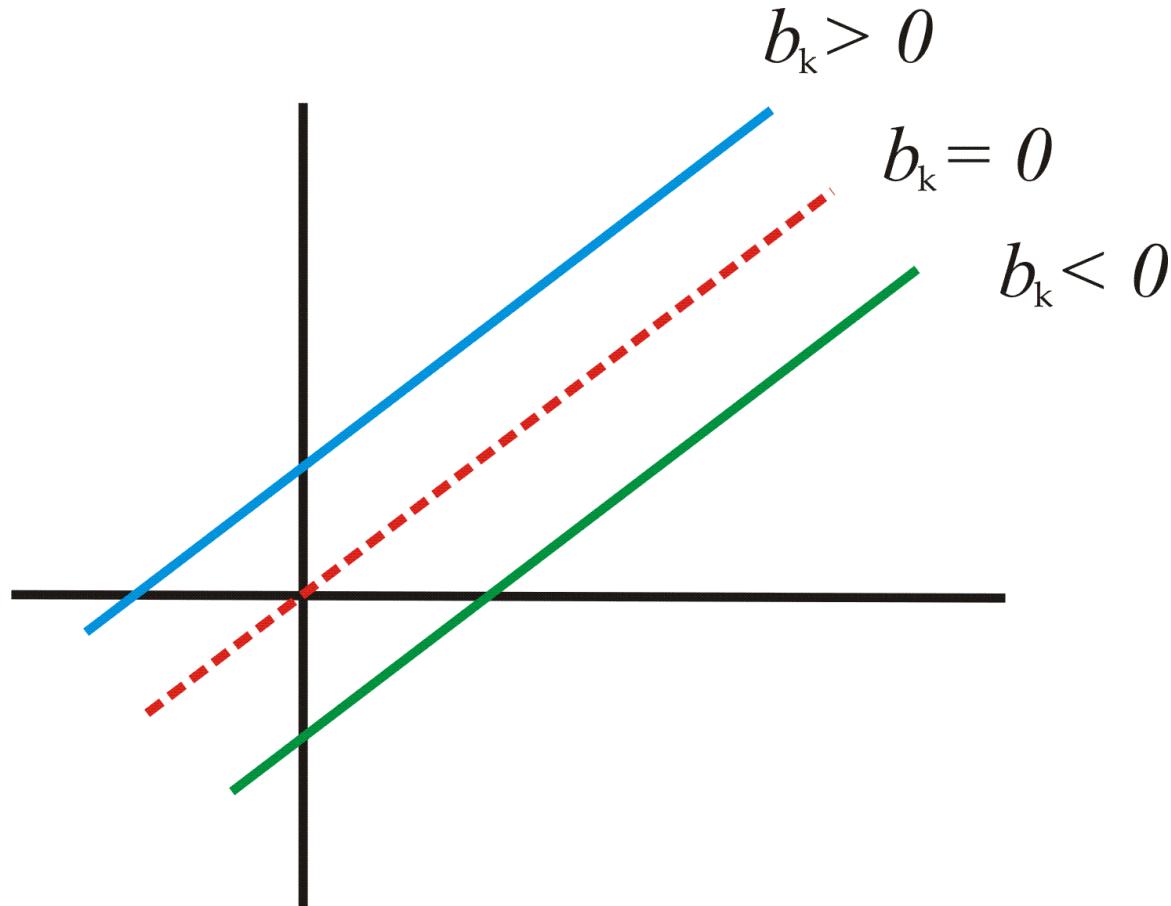
$$u_k = \sum_{j=1}^m w_{kj}x_j$$

$$y_k = \varphi(u_k + b_k)$$

Neurônio de McCulloch-Pitts

Neurônio Artificial

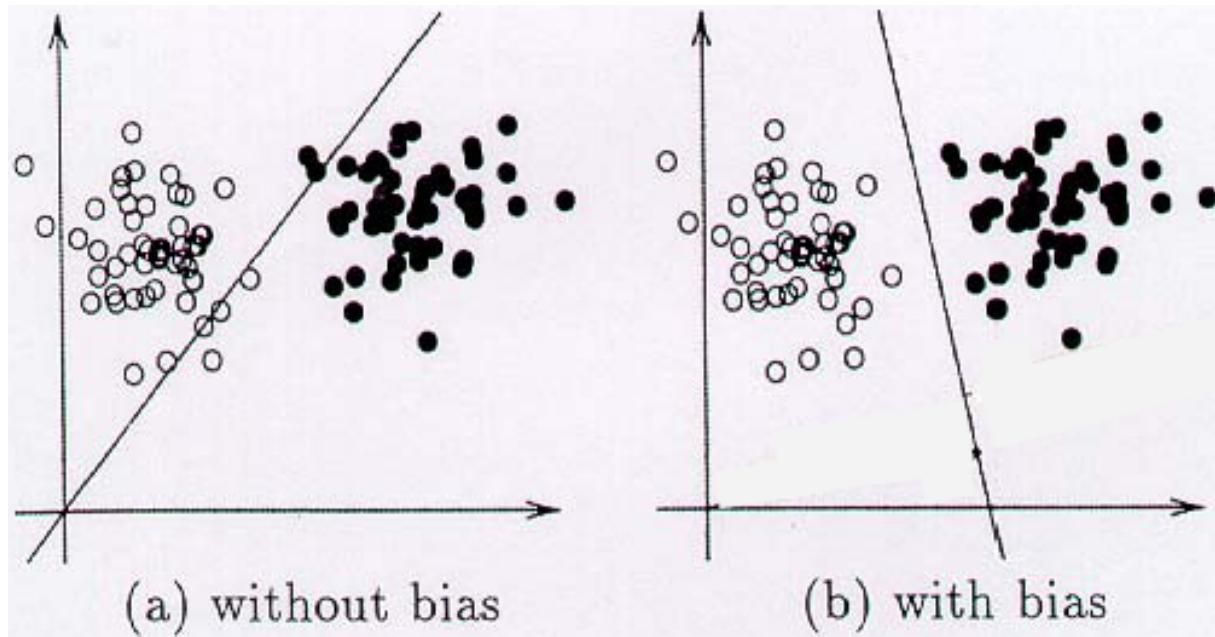
∴ **Bias**



Neurônio de McCulloch-Pitts

Neurônio Artificial

∴ Bias

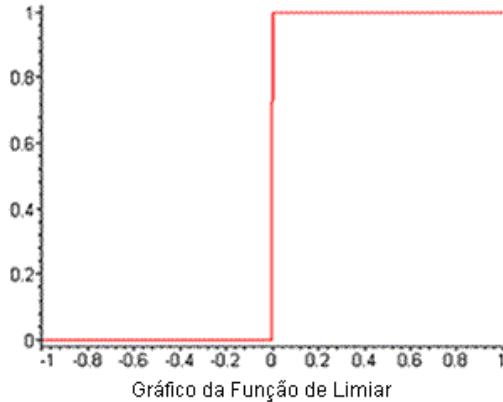


Neurônio de McCulloch-Pitts

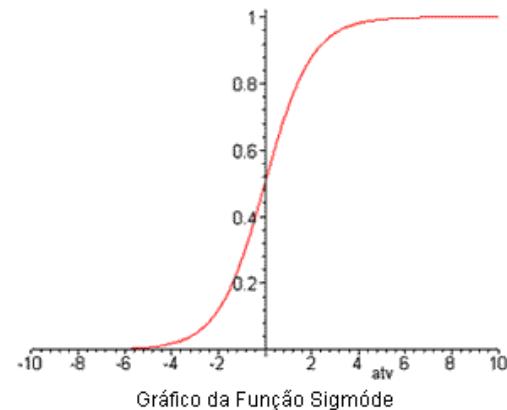
Neurônio Artificial

∴ Funções de Ativação

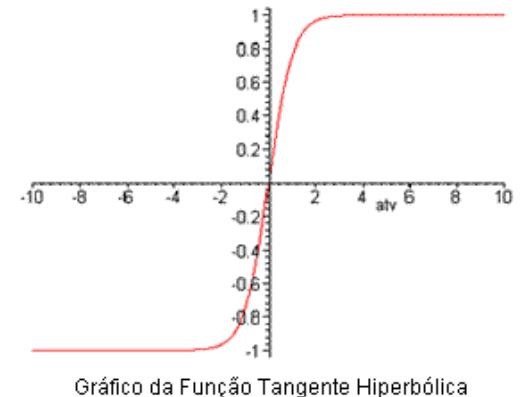
Degrau



Sigmoide



Hiperbólica



$$f(v) = \begin{cases} 1, & \text{se } v \geq 0; \\ 0, & \text{se } v \leq 0; \end{cases}$$

$$f(v) = \frac{1}{1 + e^{(-av)}}$$

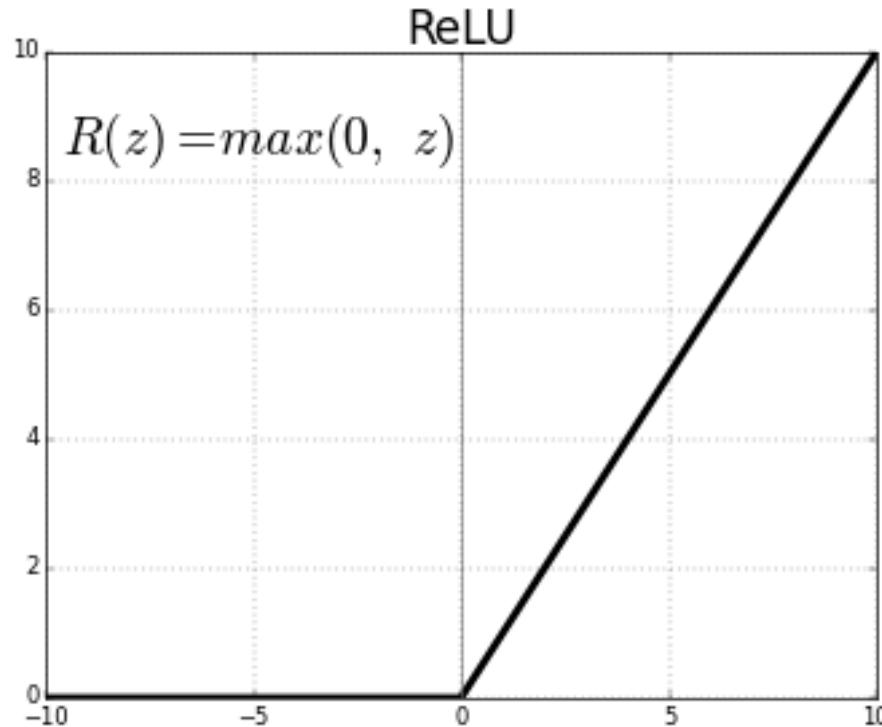
$$f(v) = a \frac{e^{(bv)} - e^{(-bv)}}{e^{(bv)} + e^{(-bv)}}$$

Neurônio de McCulloch-Pitts

Neurônio Artificial

::

Funções de Ativação

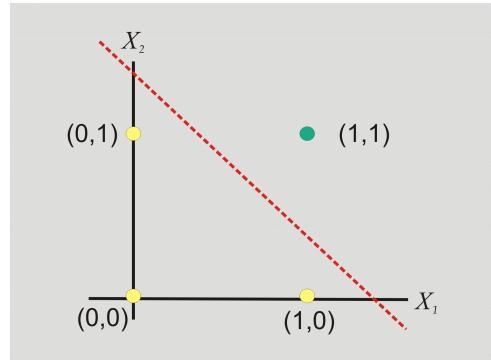
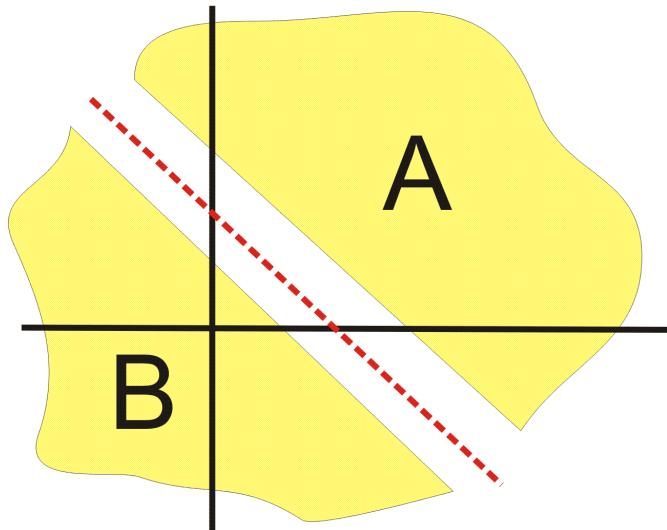


Neurônio de McCulloch-Pitts

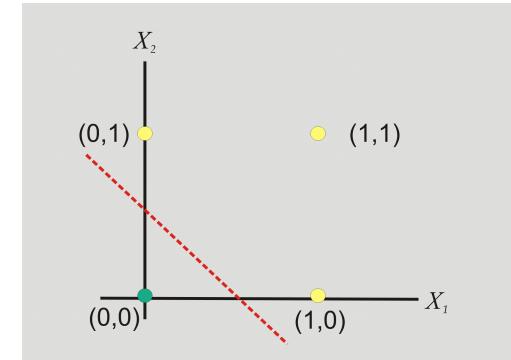
Discriminador Linear

∴ Discriminador Linear

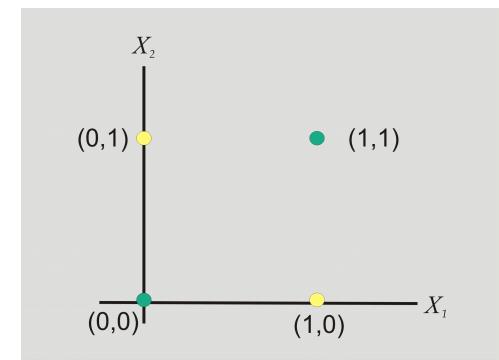
$$\sum_{i=1}^n w_i x_i = \Theta$$



“E”



“OU”



“XOR”

Histórico

∴ Histórico

Tabela 1: Eventos Históricas da Neurocomputação

ANO	AUTOR	EVENTO
1943	McCulloch & Pitts	Modelo de neurônio artificial
1949	Hebb	Regra de Aprendizagem de um neurônio
1958	Rosenblatt	Perceptron
1960	Widrow & Hoff	Adaline
1969	Minsky & Papert	XOR em “Perceptrons”
1982	Hopfield	Rede realimentada com função de energia
1986	Rumelhart & al.	Retropropagação de erro

Tabela 2: Fases da Neurocomputação

INTERVALO	FASE
1943 — 1969	Entusiasmo
1969 — 1982	Depressão
1982 — presente	Renascença

Classificação

∴ Classificação das RNAS

Supervisionadas

Rede Perceptron de Múltiplas Camadas

Rede de Funções de Base Radial

Máquina de Vetor de Suporte

Máquinas de Comitê

Redes Recorrentes

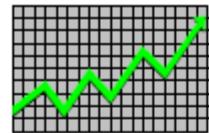
Auto-Organizáveis

Rede Competitiva

Rede de Kohonen - SOM

Outras Redes ...

Aplicações Gerais



Análise de mercado



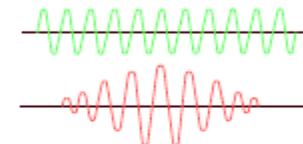
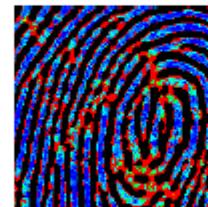
Proc. voz



Data mining



Análise de crédito



Proc. sinais



Previsão séries

Luciana de Galo Maciel



Det. fraudes



Rec. odores



Interfaces



Diagnose médica

Aplicações Gerais

Comunicação Homem x Máquina



Proc. voz

- Comandos de Voz
- Síntese de Voz
- Reconhecimento de Locutor

Automação Comercial

4532454532035

4532454532035

- Reconhecimento de Manuscritos
- Reconhecimento Frases e Palavras
- Mineração de Dados (Data Mining)

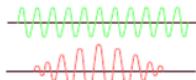
Provas Judiciais



Det. fraudes

- Identificação do Locutor
- Identificação de Impressão Digital
- Identificação de Assinaturas

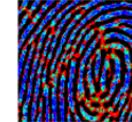
Automação Industrial



Proc. sinais

- Reconhecimento de Objetos
- Locomoção de robôs autônomos
- Controle de Servo Mecanismos

Segurança de Acesso



- Verificação por voz
- Verificação por imagem (face, iris)
- Verificação por impressão digital

Mercado Financeiro

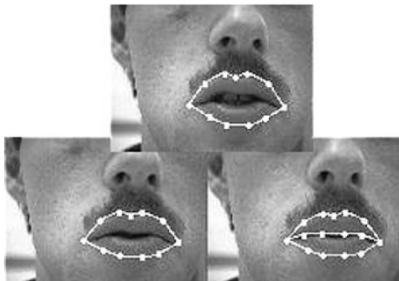


Análise de crédito

- Previsão de Mercado Futuro
- Análise de Risco
- Previsão de Falências

Aplicações

RNA com imagens



Leitura Labial



Mapeamento de imagem
para som



Reconhecimento de face

4532454532035

4532454532035

4532454532035

Reconhecimento de
letras e números



Detector de tons de pele



Análise de Digitais

Redes Neurais Artificiais

Perceptron

Flávio Henrique Duarte de Araújo
flavio86@ufpi.edu.br

Perceptron

Considerações Iniciais

::

Perceptron

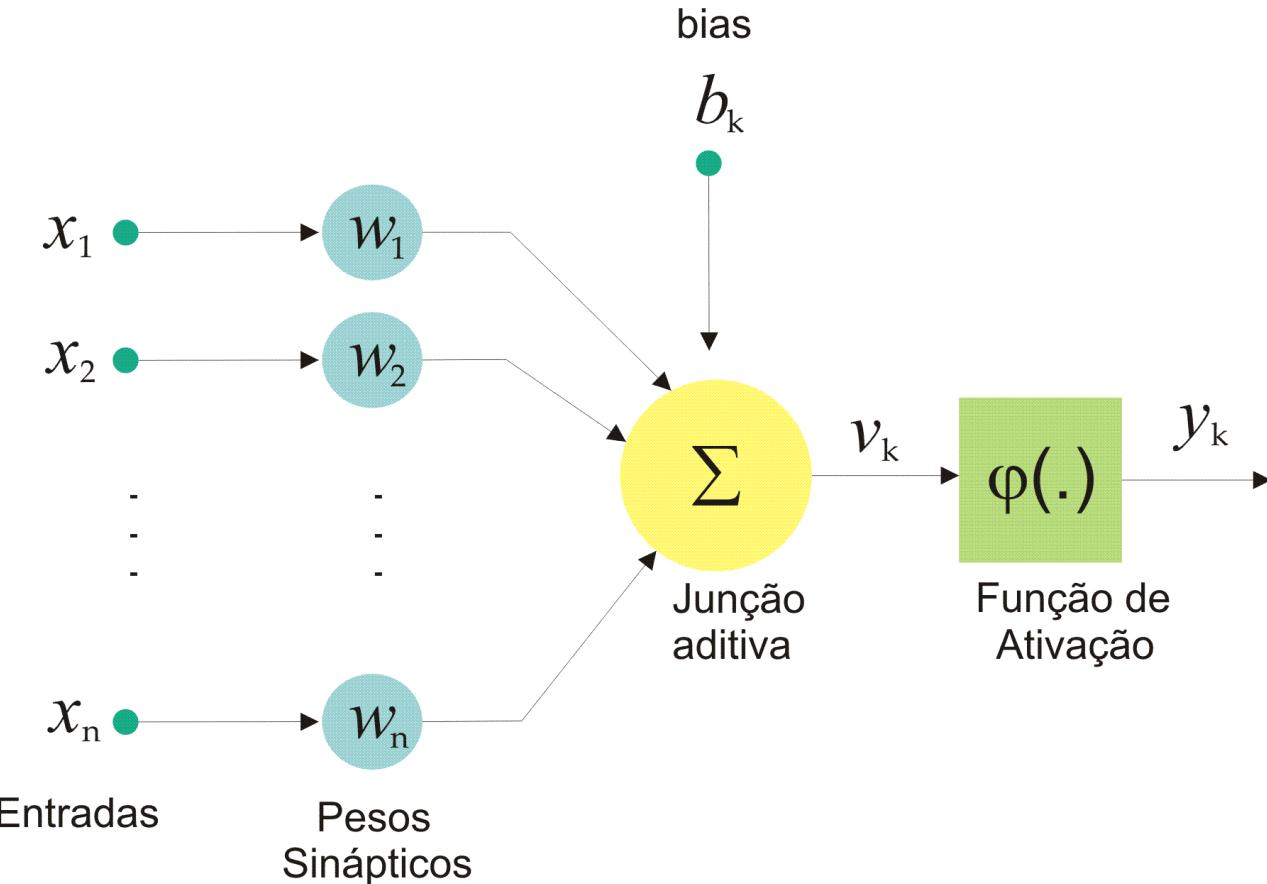
- No final da década de 50, Rosenblatt, prosseguindo as ideias de McCulloch-Pitts criou uma genuína rede de múltiplos neurônios do tipo discriminadores lineares e chamou esta rede de *perceptron*;
- Unidade básica: os neurônios MP;
- Basicamente o *perceptron* consiste de uma única camada de neurônios com pesos sinápticos e bias ajustáveis;
- Se os padrões de entrada forem linearmente separáveis, o algoritmo de treinamento possui convergência garantida, ou seja, tem a capacidade de encontrar um conjunto de pesos que classifica corretamente os dados;
- Os neurônios do *perceptron* são similares ao de McCulloch-Pitts;

Perceptron

Considerações Iniciais

∴

Neurônio

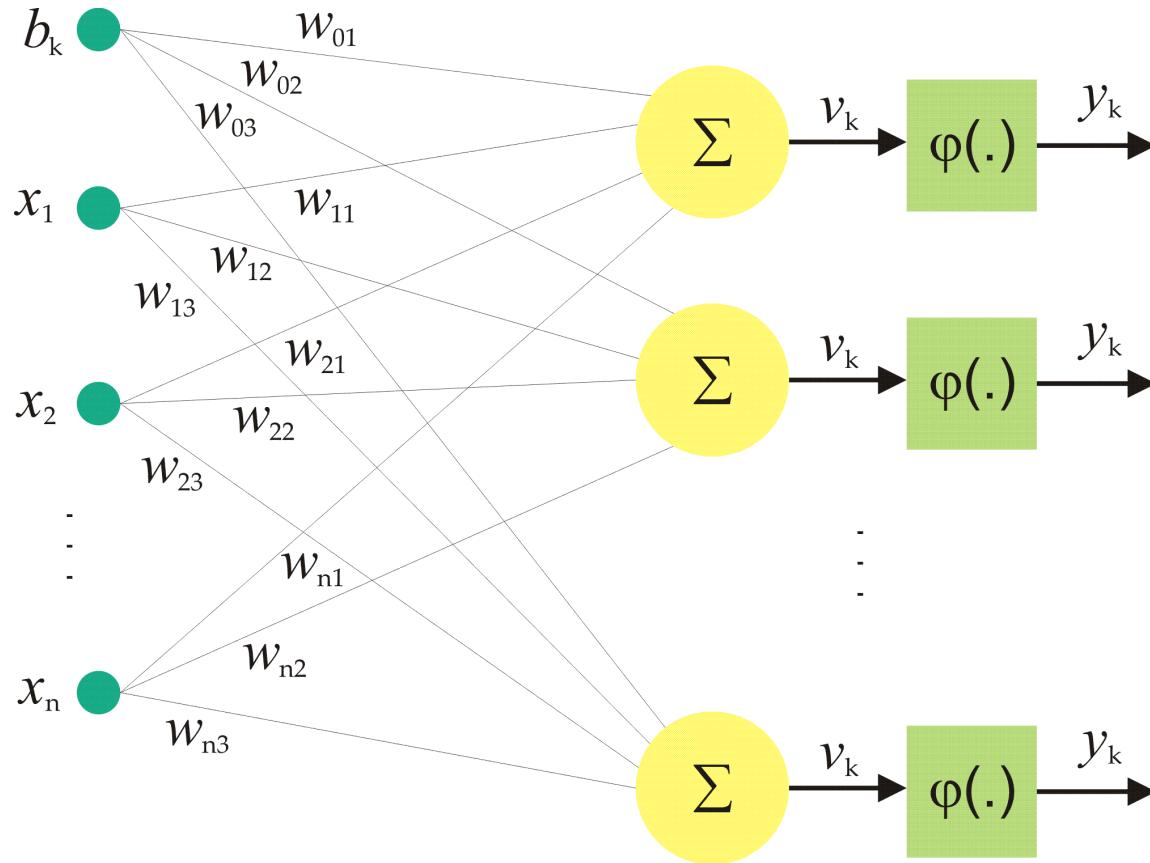


Perceptron

Considerações Iniciais

::

Perceptron

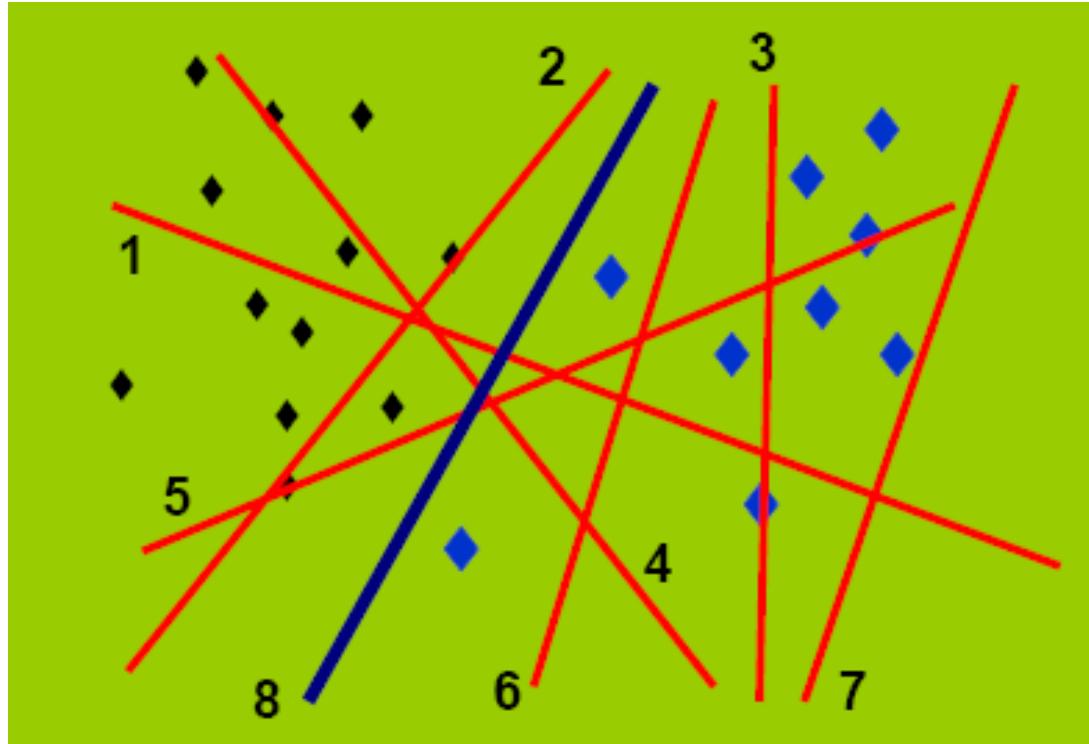


Perceptron

Algoritmo de Aprendizagem

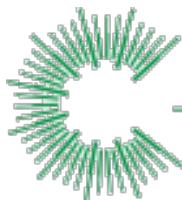
::

Treinamento



Redes Neurais Artificiais

Perceptrons de Múltiplas Camadas



Universidade Federal do Piauí
Educação Ciência Arte Inclusão Social



Flávio Henrique Duarte de Araújo
flavio86@ufpi.edu.br

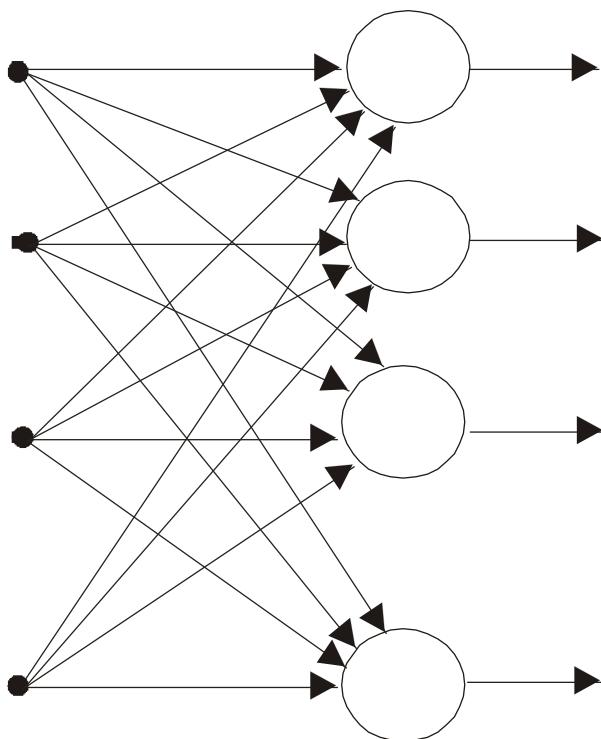
Redes Multi-Camadas

Arquiteturas

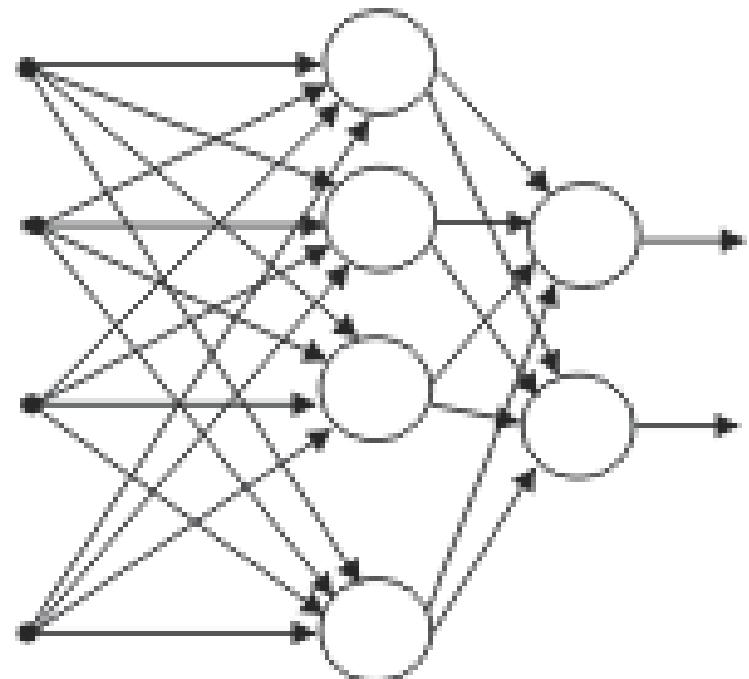
::

Arquiteturas

Rede com uma única camada



Rede de Múltiplas Camadas

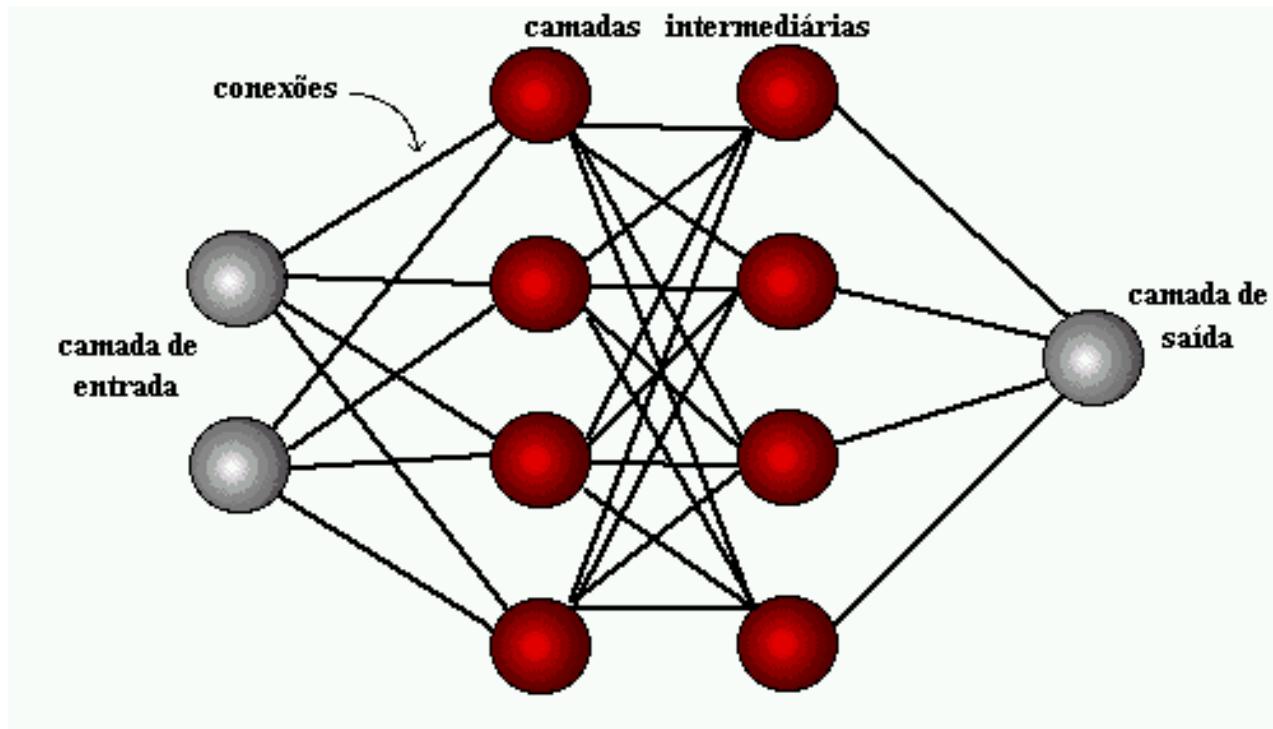


Redes Multi-Camadas

Topologias

::

Rede Multi Camadas



MLP

Redes Multi-Camadas

Projeto

::

Projeto de Redes Neurais

- Coleta e seleção de dados: aleatoricidade

Dados de treinamento

Dados de validação

- Configuração da Rede

Tipo e Topologia

Algoritmo de treinamento

Funções de Ativação

- Treinamento

Número máximo de ciclos

Taxa de erro

Taxa de Aprendizagem

Validação

Dados aleatórios

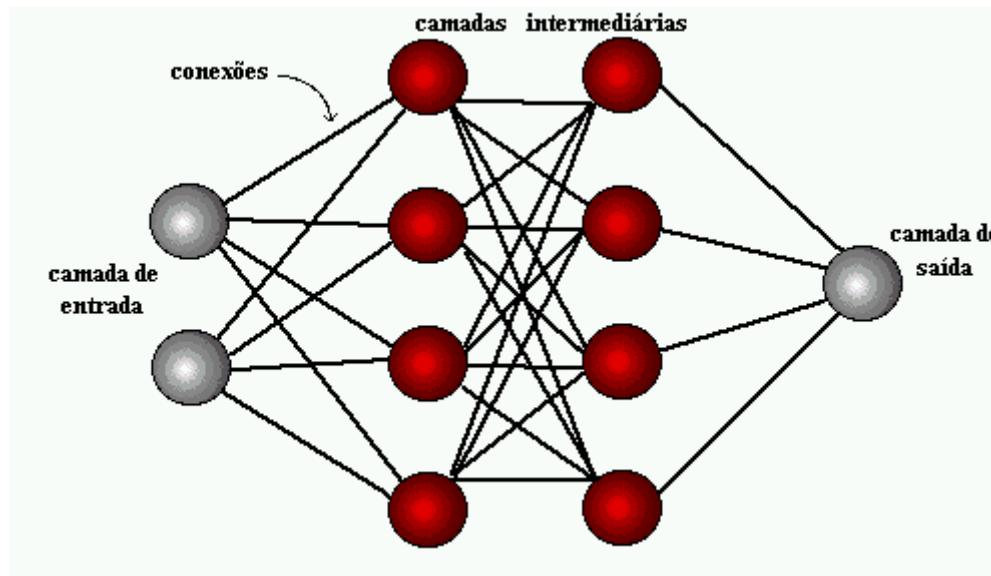
MultiLayer Perceptron ~ MLP

Considerações Iniciais

::

MLP

- Os neurônios possuem uma função de ativação não-linear, diferenciável, do tipo sigmoidal (ou tangente-hiperbólica);
- a rede possui uma ou mais camadas intermediárias; e
- a rede possui uma alta conectividade.



MultiLayer Perceptron ~ MLP

Análise das Camadas

::

MLP

- **uma camada:**

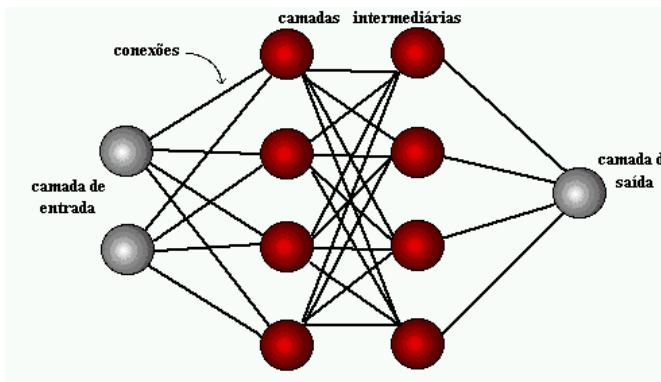
Resolve apenas problemas linearmente separáveis;

- **uma camada intermediária:**

Implementa qualquer função contínua;

- **mais de uma camada intermediária:**

Aproximar qualquer função matemática;



MultiLayer Perceptron ~ MLP

Análise das Camadas

::

MLP

- Primeira camada:

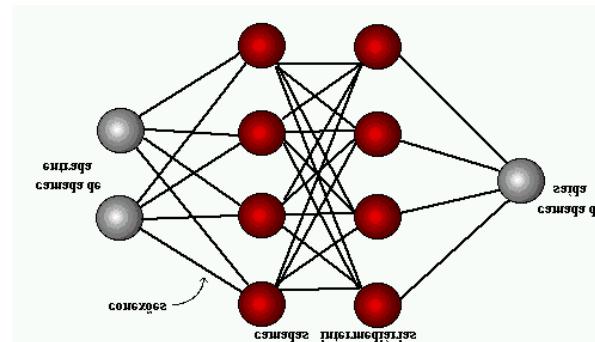
Cada nodo traça retas no espaço de parâmetros de treinamento;

- Segunda camada:

Cada nodo combina as retas formando regiões convexas onde o número de lados é definido pelo número de unidades a ele conectadas;

- Camada de Saída:

Cada nodo forma regiões que são combinações das regiões convexas;



MultiLayer Perceptron ~ MLP

Back-Propagation

:: Algoritmo Back-Propagation

- O *back-propagation* foi inventado e popularizado por Rummelhart, Hilton e Williams em 1986 resolvendo uma das limitações fundamentais para o treinamento de redes complexas
- Basicamente, a aprendizagem por retropropagação do erro consiste em dois passos atarvés das diferentes camadas da rede:
 - 1) **Propagação:** um padrão de atividades é aplicado aos nós sensoriais e é produzido a resposta real da rede;
 - 2) **Retropropagação:** os pesos sinápticos são ajustados de acordo com um sinal de erro. Este sinal é então propagado para trás na direção contrária das conexões sinápticas com o intuito de minimizar o erro médio global ou seja fazer com que a resposta real da rede se move para mais perto da resposta desejada em um sentido estatístico

MultiLayer Perceptron ~ MLP

Back-Propagation

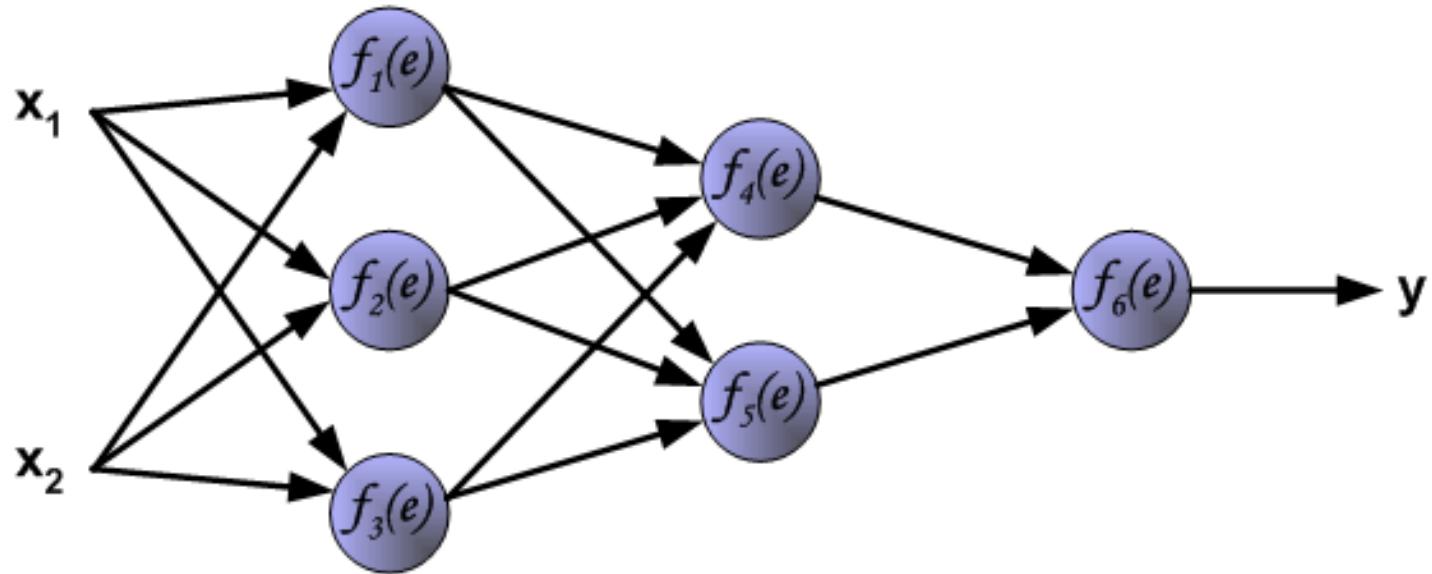
:: Algoritmo Back-Propagation

The image shows a pen lying diagonally across a sheet of graph paper. Handwritten mathematical expressions are scattered across the grid. Some of the visible text includes:

- $\frac{2ab + 6kc}{n\pi}$
- $\frac{2(ab + 5kc)}{n\pi}$
- $\sqrt{a} \sqrt{\frac{b^2 - 4n}{kc\pi}}$
- $\sqrt{b^2 - 4n}$
- $\frac{b^2 - 4n}{kc\pi}$

::

Algoritmo Back-Propagation: Visualização

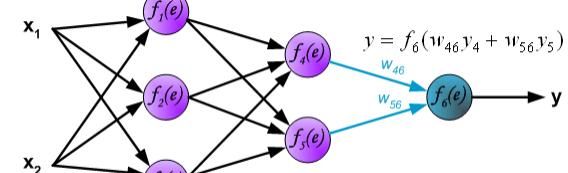
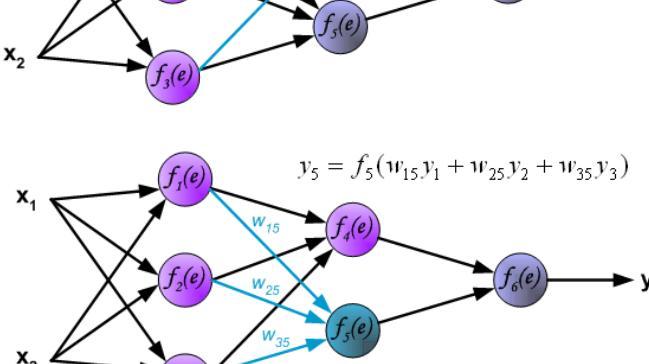
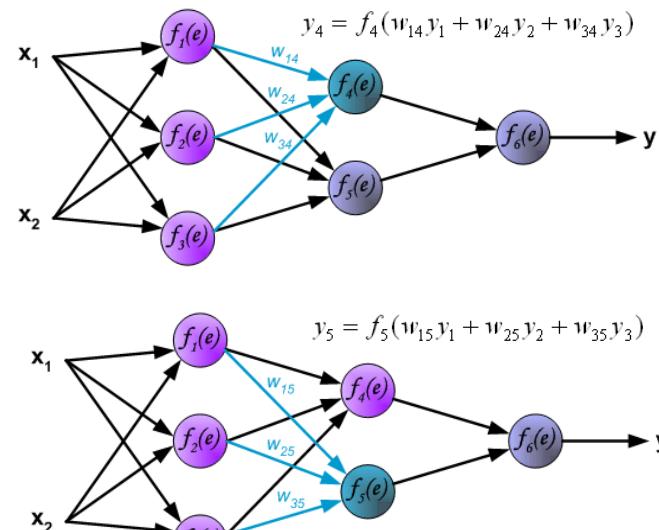
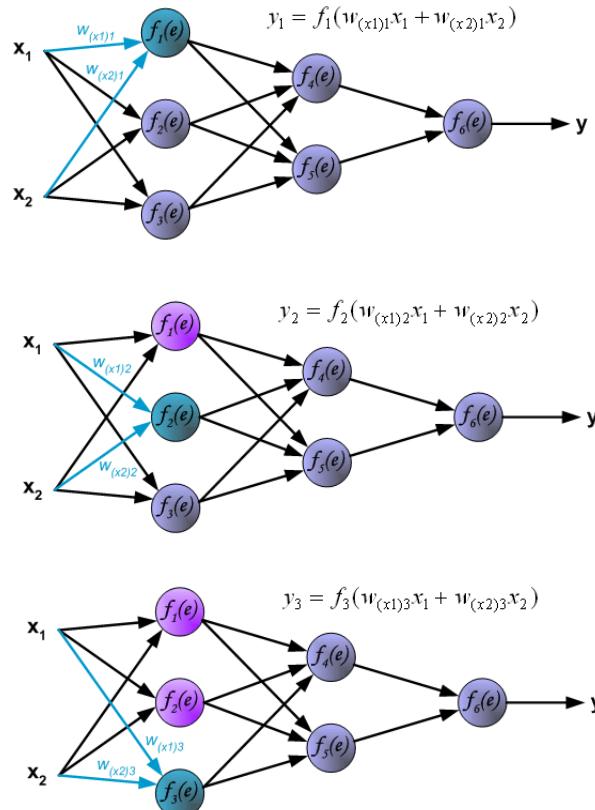


MLP

Back-Propagation

∴

Algoritmo Back-Propagation: Visualização

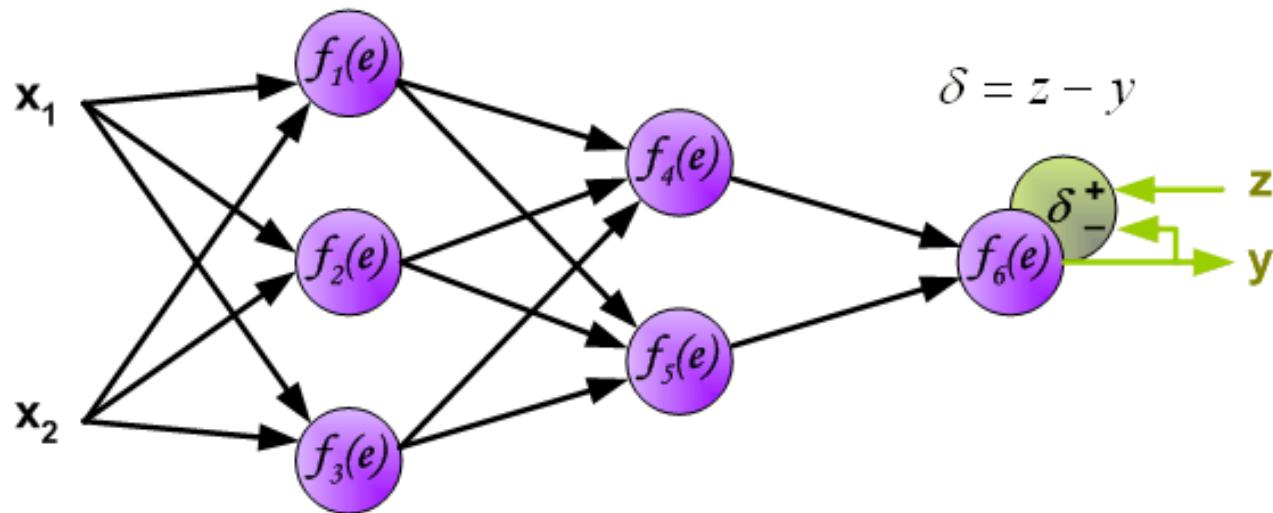


MLP

Back-Propagation

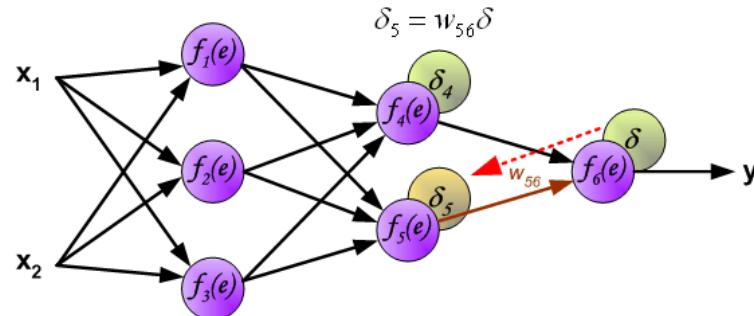
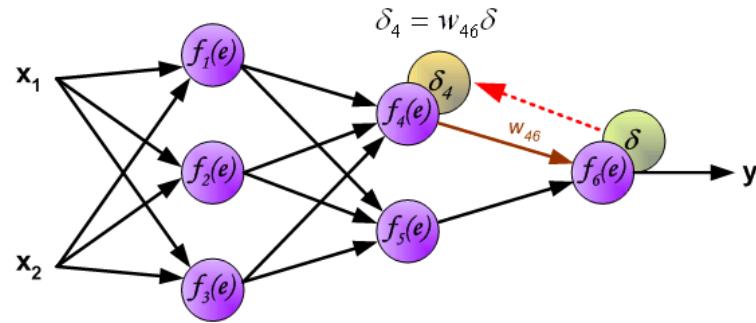
∴

Algoritmo Back-Propagation: Visualização



∴

Algoritmo Back-Propagation: Visualização

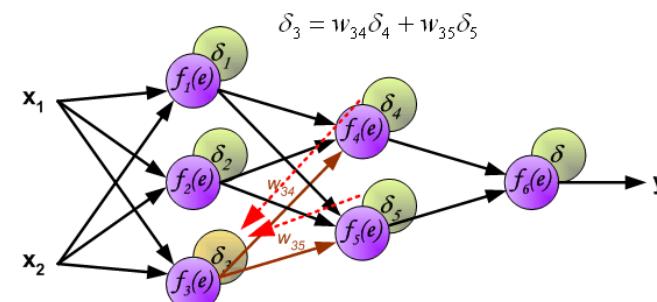
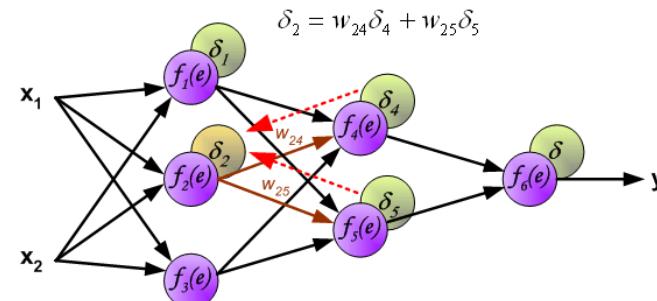
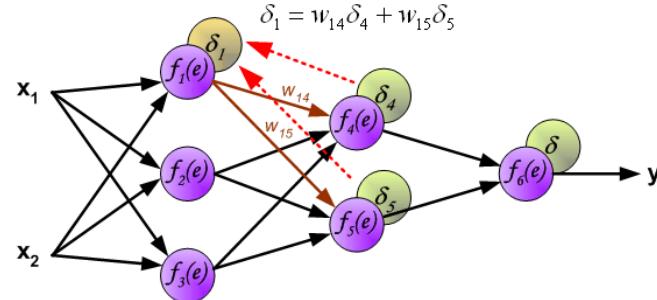


MLP

Back-Propagation

∴

Algoritmo Back-Propagation: Visualização

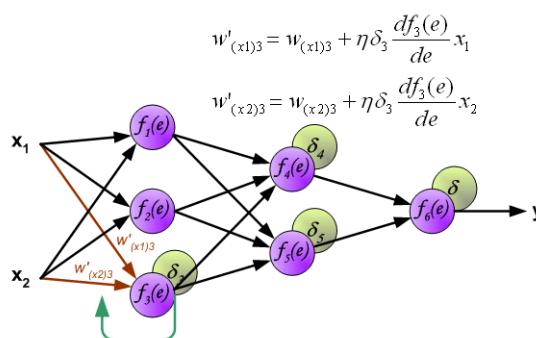
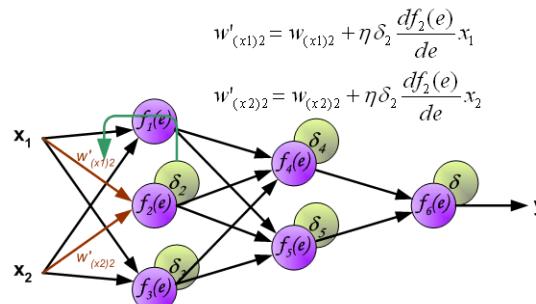
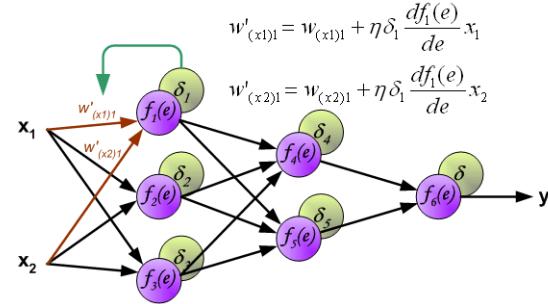


MLP

Back-Propagation

∴

Algoritmo Back-Propagation: Visualização

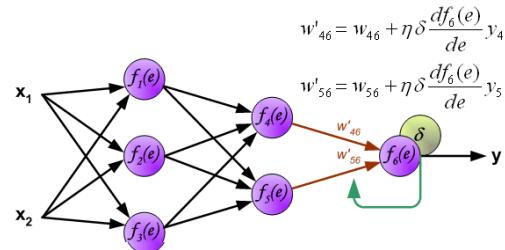
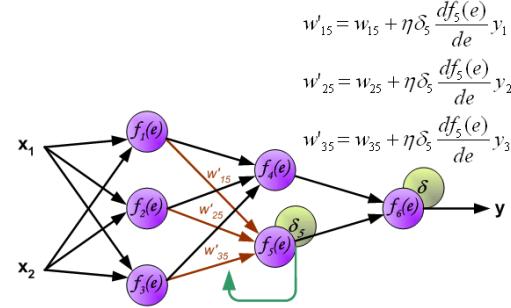
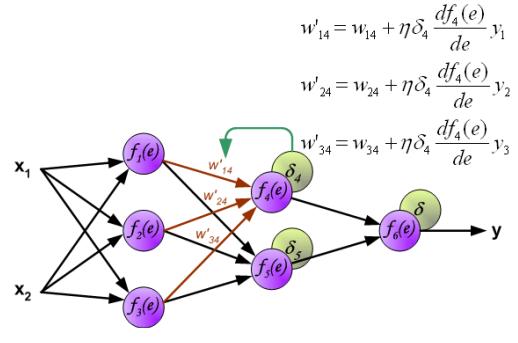


MLP

Back-Propagation

∴

Algoritmo Back-Propagation: Visualização



MultiLayer Perceptron ~ MLP

Back-Propagation

∴ Aspectos do Treinamento

- O aprendizado é resultado de apresentação repetitiva de todas as amostras do conjunto de treinamento.
- Cada apresentação de todo o conjunto de treinamento é denominada época.
- O processo de aprendizagem é repetido época após época, até que um critério de parada seja satisfeito.
- É recomendável que a ordem de apresentação das amostras seja aleatória de uma época para outra. Isso tende a fazer com que o ajuste de pesos tenha um caráter estocástico ao longo do treinamento.

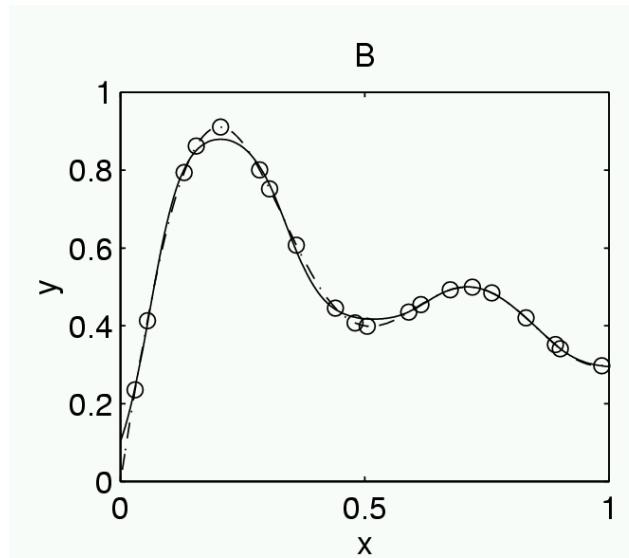
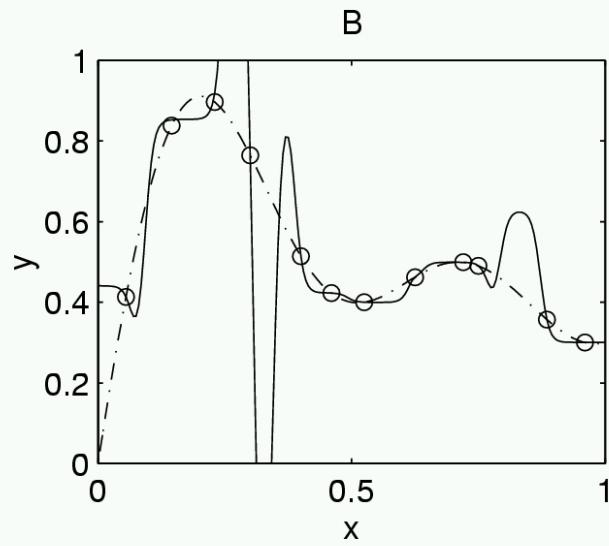
MultiLayer Perceptron ~ MLP

Overfitting

::

Quantidade de neurônio a serem usados

- Aumentando-se o número de neurônios na camada escondida aumenta-se a capacidade de mapeamento não-linear da rede.
- No entanto, quando esse número for muito grande, o modelo pode se sobre-ajustar aos dados, na presença de ruído nas amostras de treinamento. Diz-se que a rede está sujeito ao sobre-treinamento (*overfitting – hiperespecialização*”).



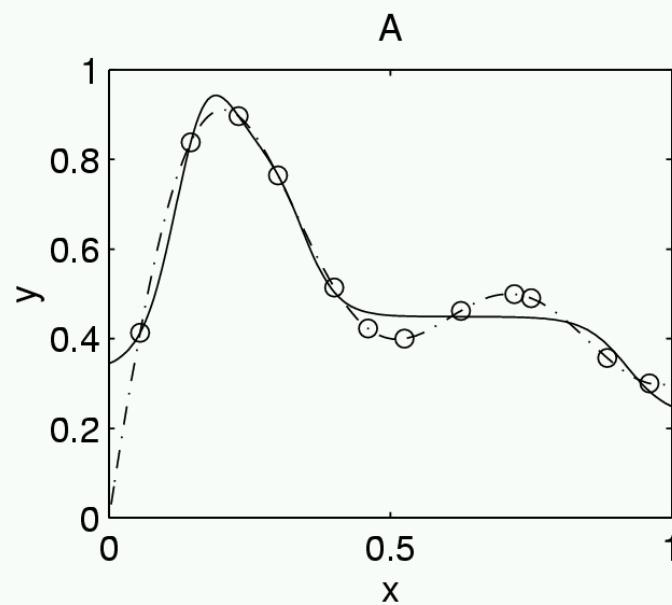
MultiLayer Perceptron ~ MLP

Underfitting

::

Quantidade de neurônio a serem usados

- Por outro lado, uma rede com poucos neurônios na camada escondida pode não ser capaz de realizar o mapeamento desejado, o que é denominado de *underfitting*.
- O *underfitting* também pode ser causado quando o treinamento é interrompido de forma prematura.



..

Pontos Positivos

- Alto Poder de Representação
- Larga Aplicabilidade
- Facilidade de Implementação
- Capacidade de Generalização

..

Pontos Negativos

- A aprendizagem de transformações complexas pode não convergir;
- Visualização como caixa preta

FIM